

DOCUMENTACIÓN CARGA FICHEROS DE GOOGLE CLOUD STORAGE EN BIGQUERY

Objetivos del sistema

Este sistema implementa un cargador dinámico de ficheros Excel (.xlsx) y CSV (.csv) que están almacenados en Google Cloud Storage para cargarlos en BigQuery. Este cargador permite:

- Detección automática de archivos nuevos en los bucket de GCS.
- Validación de la configuración de carga.
- Transformación de la información cuando es necesario, es decir, si el fichero es pivotado.
- Carga de datos en las tablas de BigQuery.
- Registro del estado de cada uno de los procesamientos en una tabla de logs.
- Generación de alertas en caso de error.

Tablas de BigQuery

En BigQuery se han generado diferentes tablas previa implementación del sistema y una vez se ejecuta.

Tabla de configuración (loader_configuration_table_regex)

Esta tabla contiene la configuración que determina cómo procesar cada archivo, es decir, permite que el sistema sea configurable sin modificar el código. Campos:

- id_load -> Identificador de la configuración.
- path -> Ruta absoluta del bucket.
- skiprows -> Filas a saltar o evitar.
- alert_email_array -> Emails a los que se notificarán los errores.
- mode -> Modo de generar la tabla consolidada.
- file_regex -> Expresión regular o patrón para buscar el nombre de los archivos.
- is_pivoted -> Si la tabla pivota o no.
- consolidated_table -> Tabla consolidada de destino de cada archivo.
- fixed_columns_count -> Número de columnas fijas.

Ejemplo de inserción de datos en configuración

```
INSERT INTO `practicas_2026.loader_configuration_table_regex`
```

```
VALUES (
```

```
  'frozen_demand',
```

```
'gs://practicass2026',
[0],
['practicass008.roadtodata@gmail.com'],
'WRITE_TRUNCATE',
'^DYNAMIC.*\\.xlsx$',
TRUE,
'r2d-interno-dev.practicass_2026.consolidated_table_DYANMIC',
1
);
```

Tabla de logs (loader_logs)

Esta tabla registra cada evento ocurrido durante el proceso. Permite realizar auditoría de ejecuciones, diagnostica -- errores y crea una trazabilidad completa de cada archivo procesado. Campos:

- log_timestamp -> Momento en el que se registra el log.--
- execution_id -> Identificador de cada ejecución del sistema.
- id_load -> Identificador de la configuración.
- source_path -> Ruta absoluta del bucket.
- source_file -> Ruta absoluta del archivo.
- target_table -> Tabla objetivo de los logs.
- is_pivoted -> Si la tabla pivota o no.
- status -> Estado del proceso.
- rows_processed -> Número de filas procesadas exitosamente.
- error_message -> Mensaje de error que lanza el sistema.
- duration_seconds -> Duración total en segundos de cada proceso.
- process_start_timestamp -> Hora y fecha de inicio del proceso.--
- process_end_tiemstamp -> Hora y fecha de final del proceso.
- error_fingerprint -> Huella que deja cada error.
- notification_sent -> Si se ha enviado notificación del error o no.
- file_generation -> Número identificativo de cada archivo.

Flujo completo del procesamiento

El sistema tiene el siguiente flujo una vez detecta el bucket donde están los archivos a procesar:

1. **Generación de la configuración en tabla de BigQuery.** Se genera una configuración en la tabla `loader_configuration_table_regex` para los ficheros que serán validados más adelante.
2. **Subida de archivos al bucket.** Se suben los archivos que se quieran procesar al bucket y a sus carpetas correspondientes.
3. **Detección del archivo.** El sistema recorre el bucket y lista todos los archivos que hay disponibles.
4. **Identificación de la versión del archivo.** Cada uno de los ficheros en Cloud Storage es como un objeto y tiene un identificador único llamado *generation*. El sistema va a utilizar la ruta absoluta del archivo más este identificador único (*source_file* + *generation*) para detectar cada versión del archivo.
5. **Comprobación del estado previo.** Una vez identificado el archivo se hace una consulta a la tabla de logs para ver si ese archivo ya fue procesado anteriormente. Si es así, ese archivo se omite. Con esto se evita no procesar archivos repetidos.
6. **Búsqueda de la configuración.** Si el archivo no fue procesado, continúa con el proceso en busca de la configuración. Ahora busca en la tabla de configuraciones si alguna coincide con el nombre del archivo. Si no la encuentra lanza el mensaje de “Configuración no encontrada” y, de lo contrario, sigue con las validaciones. Además, registrará en la tabla de logs el estado de NO_CONFIG.
7. **Validaciones.** En este punto comprueba que la extensión del archivo sea la correcta, el dataset sea el indicado y que la estructura del archivo también esté en la configuración.
8. **Registro del estado RUNNING.** Si el archivo pasa todas las validaciones previas, se registra en la tabla de logs con el estado de RUNNING, es decir, está en proceso.
9. **Lectura del archivo.** Se descarga el fichero temporalmente desde Cloud Storage y se hace una detección automática de la/las fila/s de cabecera.
10. **Transformación de los datos.** Si la configuración previa lo requiere, se realiza un pivotado de columnas en aquellos ficheros que sean dinámicos. Si no fueran pivotados, se cargaría la tabla sin ningún tipo de transformación.
11. **Carga en BigQuery.** Una vez hecha la transformación, los datos se registran en la tabla consolidada que se haya predefinido en la configuración. Cada configuración tiene su propia tabla consolidada. En cada uno de los procesos de este sistema, los ficheros con la misma configuración irán a la misma tabla consolidada y se concatenarán uno detrás de otro, así como sus diferentes pestañas. Una vez finalice el proceso, en la siguiente carga, esa tabla consolidada se limpiará (TRUNCATE) de la información que hubiera previamente y se cargará con los datos de los nuevos ficheros.
12. **Registro del estado de los resultados.** Cada uno de los ficheros actualizará en la tabla de logs su estado final sustituyendo el estado RUNNING por SUCCESS o ERROR. Si la carga en BigQuery es correcta, se registrará como SUCCESS. Si durante el proceso ocurre algún error, se registrará como ERROR y con el correspondiente mensaje de error.

13. **Archivado.** Por último, los archivos que hayan superado todo el proceso y hayan sido gestionados correctamente se moverán en el bucket a una carpeta historical donde estarán en un directorio con la fecha del día que se haya realizado ese proceso y, también, con la ruta de carpetas que tenía previamente.

Ejemplo:

gs://business/ventas/fich1.xlsx

---->

gs://business/historical/20260325/ventas/fich1.xlsx

Gestión de versiones de archivos

Para que cada archivo sea único y sea tratado de forma individual, el sistema utiliza un identificador único que Cloud Storage provee a través de sus metadatos. Ese identificador es *generation* que es una cadena de dígitos únicos para cada archivo. Con esto el sistema garantiza que cada versión de un archivo se procesa solo una vez para optimizar el proceso. Además, si el usuario vuelve a subir el archivo corregido, se detectará como una versión diferente y así tratarlo de nuevo y no ignorarlo.

Ejemplo:

Archivo	Generation	Estado
Fich1.xlsx	123456789	ERROR
Fich1.xlsx	987654321	SUCCESS

Gestión de errores

El sistema detecta y clasifica los errores según categorías:

- **NO_CONFIG:** No existe configuración para este archivo.
- **INVALID_EXTENSION:** La extensión del archivo no está permitida, es decir, no es ni .xlsx ni .csv.
- **PROCESSING_ERROR:** Errores que ocurren durante el procesamiento.
- **BQ_LOAD_ERROR:** Errores registrados en la carga en BigQuery.

Todos estos errores que ocurran durante el proceso quedan registrados en la tabla de logs junto con el mensaje de error, la hora y fechas exactas, el identificador único del archivo y la huella de error.

Sistema de notificaciones

Los errores que se registren durante el proceso, aparte de quedar registrados en la tabla de logs, se genera una huella única de error. Esta huella incluye el archivo, la versión (*generation*), la configuración aplicada y el tipo de error. Con esta huella se consulta si ese error fue notificado ya previamente vía correo. Si no es así, se envía la alerta y si ya lo fuera, ignora el error y no se reenvía para evitar múltiples alertas por el mismo problema.

Gestión de archivos en Cloud Storage

Los archivos en el bucket se comparten de manera que si un archivo es válido y ha logrado todo el proceso se mueve a una carpeta interna llamada *historical*. Y dentro de esa carpeta se genera otra con el día en que se lleva a cabo el proceso, donde se guardará el archivo procesado con su ruta de carpetas que tuviera en el bucket. Si ocurre un error de procesamiento o no existe configuración para ese fichero, permanecen en el bucket. Y, si el usuario, sube una nueva versión de uno de los ficheros que ya estaba en el bucket, se volverá a procesar porque se trata como un archivo totalmente diferente.

Control de concurrencia

Para evitar que un mismo archivo sea procesado simultáneamente por dos ejecuciones del sistema, se ha generado un estado RUNNING en la tabla de logs. Cada archivo que es validado y listo para ser procesado generará un log en la tabla de logs donde se registrará como RUNNING. De esta manera, si otra ejecución intenta acceder a ese mismo archivo verá que el estado es RUNNING, lo omitirá e irá a por el siguiente. Esto evita duplicación de cargas e inconsistencia en los datos. Una vez el archivo es procesado finalmente, se actualizará el estado del proceso a SUCCESS o ERROR.